

ENDIREH 2021 | Práctica 4

Medidas descriptivas, heterogeneidad y concentración

Resumen ejecutivo del conjunto consolidado | Almacenes y Minería de Datos

Se analizaron 105,715 registros. Los casos ponderados presentan concentración territorial (Gini 0.4180), mientras que el estado civil muestra diversidad de categorías. Estos resultados descriptivos no identifican causas ni riesgos individuales.

Tabla de resultados

Familia	Variables	Valor obtenido	Interpretación
Localización	Edad de primera unión y número de hijos	edad_primer_union: media pond. 19.74, mediana pond. 17. num_hijos: media pond. 1.85, mediana pond. 1	La edad usa los datos válidos. Hijos incluye los valores rellenados con cero.
Variabilidad	Edad de primera unión y número de hijos	edad_primer_union: CV 48.56%, IQR 13. num_hijos: CV 70.36%, IQR 2	El IQR de edad es 13 años y el de hijos es 2. Ambos se calcularon sin ponderar.
Heterogeneidad	Violencia de pareja y estado civil	Violencia: H 0.6836, IQV 0.5945. Estado civil: H 2.2176, IQV 0.8945	Muestra cómo se reparten las respuestas. No permite saber si hay subregistro.
Concentración	Casos ponderados por entidad	Gini 0.4180, área Lorenz 0.2910	Los casos no se reparten por igual. También influye el tamaño de la población.
Gini vs. entropía	Estado civil (6 categorías), ponderado	H 2.2466 bits, Gini de frecuencias 0.3717	Shannon mide diversidad y Gini mide desigualdad entre las frecuencias.

Alcance y decisiones

La edad de primera unión tiene 90.59% de faltantes. Los estadísticos de edad usan casos válidos. Hijos incluye ceros imputados. Media y mediana ponderadas usan factor_expansion. CV, IQR e índices de heterogeneidad son muestrales. Lorenz usa cantidades ponderadas, y la síntesis compara los dos índices sobre frecuencias ponderadas.

Localización y variabilidad




Figura 1. Histograma muestral de edad de primera unión. Solo casos válidos.




Figura 2. Boxplots muestrales por respuesta de violencia. Sin ponderar.

Edad: media ponderada 19.74 años y mediana ponderada 17. El IQR muestral es 13 años. Ambos grupos tienen mediana simple de 18 años e IQR de 13. Las diferencias descriptivas no demuestran causalidad. La abundancia de faltantes puede sesgar la selección de casos válidos.

NumPy calcula la media y la mediana ponderadas (inversa empírica, sin interpolación). Polars calcula cuantiles simples y varianza. SciPy stats.variation calcula el CV muestral con $ddof=1$. Los notebooks separados contienen las tablas completas.

Heterogeneidad y concentración




Figura 3. IQV muestral: se muestra una representación por variable, sin duplicar códigos y etiquetas.

Dinero propio y trabajo de la pareja presentan categorías casi equilibradas. Ahorros tiene menor diversidad. La asimetría de violencia describe respuestas de la muestra y no demuestra subregistro. Shannon está en bits, Gini-Simpson mide diversidad e IQV la normaliza según el número de categorías.




Figura 4. Lorenz de casos ponderados. Cada entidad es una unidad de igual peso en el eje horizontal.

Gini = 0.4180, área = 0.2910. El cálculo por frecuencias ordenadas coincide con $1 - 2 \times \text{área}$. La curva refleja desigualdad de cantidades y también diferencias de población. No permite asignar un riesgo a cada entidad.

Porcentaje ponderado por entidad




Figura 5. Porcentaje de respuesta afirmativa entre la población representada por cada entidad: $100 \times \text{suma}(\text{violencia} \times \text{factor_expansion}) / \text{suma}(\text{factor_expansion})$.

Esta figura incorpora el denominador poblacional, a diferencia de Lorenz. Es una prevalencia descriptiva del indicador disponible en el archivo del curso. No se presentan intervalos porque no se dispone de todas las variables del diseño muestral. No debe confundirse con denuncia administrativa ni presentarse como estimación oficial de INEGI.

Síntesis: Gini y entropía sobre estado civil

Para estado civil obtuvimos una entropía ponderada de 2.2466 bits y un Gini de frecuencias de 0.3717. Shannon muestra qué tan repartidas están las respuestas entre las seis categorías. Su máximo es $\log_2(6)$, aproximadamente 2.5850. El Gini muestra qué tan desiguales son las frecuencias de esas categorías. Los dos usan los mismos datos, pero responden preguntas distintas. Sin ponderar, Shannon es 2.2176. La diferencia se debe al factor de expansión. Estos índices no muestran la relación entre estado civil y violencia. Tampoco hay que confundir el Gini de concentración con Gini-Simpson, que mide diversidad.

Cuestionario y reflexión

1. ¿Qué muestran Lorenz y Gini?

Obtuvimos un Gini de 0.4180 y la curva quedó por debajo de la diagonal. Esto muestra que los casos ponderados no se reparten por igual entre las entidades. Sin embargo, sus poblaciones son distintas. Tener más casos no significa necesariamente tener un porcentaje mayor de violencia. Por eso también revisamos el porcentaje de cada entidad. El Gini que calculamos resume la concentración entre todas las entidades, no es un índice para cada estado.

2. Limitaciones y mejoras concretas

Una limitación es la cantidad de edades faltantes. Otra es haber rellenado hijos con cero, porque eso puede cambiar su distribución. También eliminamos duplicados sin tener un identificador de entrevista que permita comprobar cada caso. Las respuestas de la encuesta dependen de lo que las personas estén dispuestas a contar, pero estos cálculos no permiten saber cuánto subregistro hay. Como mejoras, revisaríamos los códigos y las preguntas del cuestionario y compararíamos los resultados de hijos con y sin los ceros imputados. También buscaríamos identificadores y variables del diseño muestral para revisar los duplicados y calcular intervalos de confianza. Para analizar municipios primero habría que revisar si hay suficientes datos y cuidar la privacidad de las personas.

3. ¿Cómo orientan decisiones posteriores?

Las medidas de localización y variabilidad ayudan a revisar los valores extremos y las decisiones de limpieza. La heterogeneidad permite ver qué variables tienen categorías equilibradas y en cuáles predomina una respuesta. La concentración ayuda a ver dónde se acumulan más casos, pero para decidir dónde hacen falta recursos también hay que revisar los porcentajes y el tamaño de la población. Para elegir variables de un modelo necesitaríamos estudiar su relación con la violencia y validar sus resultados. Estas medidas no bastan para identificar causas o grupos con mayor riesgo.

4. Consideraciones éticas y de comunicación

Al presentar las gráficas hay que explicar qué datos usamos, cómo se ponderaron y qué valores faltan o se rellenaron. Debemos distinguir las respuestas de la encuesta de las denuncias y los totales de casos de los porcentajes. No sería correcto llamar violentos a ciertos estados ni asumir que en los que tienen menos casos el problema es menor. Si analizamos grupos más pequeños, tenemos que cuidar su privacidad. Los resultados son del archivo del curso y no deben presentarse como cifras oficiales de INEGI.

Método, reproducibilidad y fuentes

Usamos los datos de ENDIREH 2021 que limpiamos en la práctica 3. El archivo tiene 105,715 registros y 31 columnas. Trabajamos con Parquet y también guardamos una copia en CSV. Falta la edad en 95,764 registros (90.59%). No la rellenamos porque faltan demasiados datos. Los cálculos de edad usan los 9,951 registros que sí tienen dato. En hijos se rellenaron 19,231 valores con cero en la práctica 3. Esa decisión puede afectar los resultados. Elegimos edad e hijos para describir las características demográficas. Para heterogeneidad usamos escolaridad, estado civil y condiciones económicas. Para concentración agrupamos por entidad. Usamos Polars para cargar y agrupar los datos, NumPy para los índices y SciPy para el CV con `stats.variation` y `ddof=1`. Las gráficas se hicieron con Matplotlib y Seaborn. Las funciones de los índices están en `src/analysis/indices.py`. Los notebooks reúnen los cálculos y las interpretaciones. Git guarda los cambios del proyecto. La media y la mediana ponderadas usan `factor_expansion`. Para la mediana ordenamos los valores y tomamos el primero cuyo peso acumulado llega al 50%. La variabilidad y la heterogeneidad se calcularon sin ponderar para describir la muestra. Los casos por entidad y sus porcentajes sí usan el factor de expansión. En la comparación de Gini y Shannon calculamos una versión sin ponderar y otra ponderada para ver la diferencia.

Cómo reproducir la entrega

Desde la raíz: activar `.venv`, instalar `requirements.txt` y ejecutar `python -m src.cleaning.limpiar_datos` si no existe el archivo procesado. Después, `python -m src.reporting.practica4` recalcula figuras y tablas y genera este PDF. Los notebooks presentan cada análisis por separado. Los datos originales y procesados no se versionan. El CSV original se entrega por separado.

Fuentes

INEGI (2022). ENDIREH 2021. Fuente del consolidado utilizado: <https://www.inegi.org.mx/programas/endireh/2021/>

INEGI. ENDIREH 2021, estructura de la base de datos. Referencia para revisar códigos y universos. La revisión del consolidado sigue siendo una mejora pendiente.

Gini, C. (1912). Variabilità e mutabilità. Shannon, C. E. (1948). A Mathematical Theory of Communication. Wilcox, A. R. (1973). Indices of Qualitative Variation and Political Measurement.

AyMD_Practica_4.pdf, material del curso. Las referencias a pasos 8 y 9 se interpretan como las visualizaciones y la tabla resumen del desarrollo. Se conserva la arquitectura de la práctica 3 y la ausencia de edades se declara explícitamente.